Dados do Caça-Alucinações

Como estão organizados os documentos de entrada, a base canônica `desafio1_bracis.db` e o gabarito — e como usar a base para decidir se uma citação é `real`, `inventada` ou `incompleta`.

§1 A tarefa

Encontrar as citações num documento judicial e classificar cada uma em três classes.

A entrada é um `.txt` por documento. A saída é um JSON por documento, com uma entrada por citação: o span em codepoints Unicode (`inicio` , `fim` exclusivo), o trecho literal, o tipo (`lei` ou `jurisprudencia`) e a classe. Opcionalmente, a `confianca` (0–1) de que a classe — e o link, se `real` — está correta: ela alimenta o bônus de calibração de até 10%, e quem não a envia não ganha nem perde por isso. Na entrega final, o JSON completo é obrigatório, com todos os campos — independentemente de quais entram na métrica.

O alinhamento entre a predição e o gabarito é por sobreposição de spans com **IoU ≥ 0,5** — não é preciso acertar a borda exata, mas quem não entrega o span de uma citação não consegue classificá-la, e isso conta como erro de recall.

`real`

A citação resolve a um único **registro** da base canônica. Exige `id_canonico` : acertar o rótulo sem o doc_id correto não conta.

`inventada`

Identificadores suficientes para buscar, mas nenhum registro correspondente existe na cobertura congelada.

`incompleta`

Informação insuficiente para formular a consulta, ou suficiente para buscar mas insuficiente para identificar um único registro.

§2 Os documentos de entrada

Vinte e seis peças jurídicas sintéticas, divididas em dois níveis de dificuldade — pesos 1× e 2× na nota.

Esta é a **amostra de desenvolvimento**, distribuída com gabarito para as equipes construírem e depurarem suas soluções. O conjunto final — cego — tem o mesmo formato, os mesmos níveis e distribuição de classes equivalente; ele não é distribuído: ao fim da janela, a organização executa o código submetido pelas equipes sobre esse conjunto, e é dele que sai o ranking oficial.

São petições, pareceres, decisões monocráticas e memoriais fictícios que citam acórdãos reais do acervo. Cada documento tem uma matéria coerente — cível, penal, trabalhista, eleitoral ou militar — que amarra o cabeçalho, os tribunais citados e as normas invocadas: um agravo cível não cita apelação da Justiça Militar.

A nomenclatura dos arquivos já entrega o nível: `gen_n1_001` … `gen_n1_013` são os documentos do nível 1 e `gen_n2_001` … `gen_n2_013` , os do nível 2. O nome do arquivo em `data/txt/` (sem a extensão) é o `documento_id` usado no gabarito e na submissão.

	NÍVEL 1 — FORMATO PADRÃO	NÍVEL 2 — RUÍDO E VARIAÇÃO
Peso na nota	1×	2×

Documentos	13	13
Citações	99	93
Tamanho médio	3.393 chars	3.277 chars
Classes	`real 52` `inventada 32` `incompleta 15`	`real 44` `inventada 32` `incompleta 17`
O que testa	Reconhecer a citação e resolver o doc_id na base canônica.	Normalização robusta antes de verificar: casar variantes de superfície ao mesmo identificador.

Neste repositório, `gen_n1_003`, `gen_n1_006` e `gen_n1_010` foram ajustados ao gabarito vigente, com a inserção de “AgInt no ” e “ED no AgR no ” antes da classe processual citada. Com isso, os 192 spans do gabarito batem exatamente com os textos de `data/txt/`.

A mesma classe, escrita de dois jeitos

As citações do nível 2 apontam para registros igualmente válidos — o que muda é a superfície. Todas as amostras abaixo são `real`:

NÍVEL 1

AREsp nº 1.996.496/RJ

Recurso em Habeas Corpus nº 57.763/PR

RSE nº 7000592-58.2025.7.00.0000/DF

Súmula Vinculante 10

NÍVEL 2

AgRg no Rec. Esp. n. 1.522.200 (SC)

Recurso em Habeas Corpus nº 93967 - SC

Rec. Esp. No 1.880.529
- SP

5úmula 211 do STJ

O ruído do nível 2 combina variantes de abreviação (`REsp` / `R.Esp.` / `Recurso Especial`), formatação do número (`1.741.784` / `1741784` / `1.741. 784`), separador de UF (`/PR` , `- PR` , `(PR)`), confusões de OCR (`0 ⇔ O` , `1 ⇔ l` , `5 ⇔ S` , `m ⇔ rn`) e quebras de linha no meio do identificador.

GARANTIA DO RUÍDO

Um dígito nunca é trocado por outro dígito. Isso mudaria a identidade da citação e transformaria uma `real` ruidosa numa `inventada` de fato. Todo ruído aplicado a uma citação real é recuperável por normalização — que é exatamente o que o nível 2 mede.

Distratores

Os cabeçalhos trazem números que parecem citação e não são: número dos autos em formato CNJ, protocolo, inscrição na OAB, `fls. 234/567` , valor da causa. Nenhum está no gabarito — extraí-los conta como falso positivo.

Atenção à distinção no formato CNJ: o número dos autos do próprio documento, no cabeçalho, é distrator; a referência a outro processo em formato CNJ, no corpo do texto, é citação (como o `RSE nº 7000592-58.2025.7.00.0000/DF` do quadro acima).

§3 A base canônica

> Um SQLite de 94 MB, em `data/desafio1_bracis.db`, com os 1.014 registros que definem o universo do desafio. É contra ele que uma citação é real ou inventada.

O banco é a **cobertura congelada**: um snapshot. Não se consulta base viva, e é isso que torna a avaliação reproduzível. Se um acórdão existe no mundo mas não está aqui, para efeito do desafio ele não existe — e, por construção, isso nunca prejudica ninguém: toda citação `real` dos documentos resolve dentro da cobertura. O caso-limite "registro real fora da cobertura" não ocorre neste dataset; se ocorresse, a citação seria excluída do scoring, não anotada como `inventada`.

COLUNA	TIPO	DESCRIÇÃO
`documento_id`	TEXT	Chave primária. `doc_0201` para acórdãos; o próprio doc_id para súmulas e leis.
`id`	INTEGER	**O doc_id canônico do Jusbrasil.** É este número que vai em `resolucao.id_canonico`.
`tribunal`	TEXT	STF, STJ, TSE, TST, STM. Nulo para dispositivos de lei.
`ano, relator`	INT, TEXT	Só os acórdãos têm.
`natureza`	TEXT	acordao · sumula · dispositivo
`tipo`	TEXT	jurisprudencia · lei — o enum do contrato.
`texto`	TEXT	Inteiro teor.
`texto_len`	INTEGER	Comprimento em caracteres.

`natureza` existe porque `tipo` sozinho não separa acórdão de súmula — os dois são `jurisprudencia`.

NATUREZA	REGISTROS	O QUE SÃO
`acordao`	996	Acórdãos de STF, STJ, TSE, TST e STM.
`sumula`	5	Súmulas do STJ, STF e TST, incluindo vinculante.
`dispositivo`	13	Artigos de CPC, CC, CLT, CF/88, CPP, CPM, CDC, Código Eleitoral e LC 64/1990.

Há ainda uma tabela virtual `documentos_fts` (FTS5, *external content*) indexando o texto integral dos 1.014 registros. Ela não duplica o conteúdo — aponta para `documentos` pelo `rowid`.

§4 O gabarito

O `goldenset.csv` tem uma linha por citação esperada — 192 no total, nos 26 documentos.

É o gabarito da amostra de desenvolvimento. O gabarito do conjunto final tem o mesmo formato, permanece com a organização e é usado exclusivamente na avaliação oficial.

O arquivo **não está neste repositório**: é distribuído pela organização na aba Data da competição no Kaggle.

COLUNA	DESCRIÇÃO
`nivel`	1 ou 2 — define o peso na nota final.
`documento_id`, `citacao_id`	Identificam a citação. `gen_n1_004` + `g3` — o `n1` / `n2` no nome indica o nível do documento.
`inicio, fim`	Span em codepoints Unicode, fim exclusivo. Chave de junção com a predição.
`trecho`	Cópia literal de `texto[inicio:fim]`. Quebras de linha aparecem escapadas como `\n`.
`tipo`	`lei` ou `jurisprudencia`.
`classificacao`	A classe esperada. É o que se pontua.
`id_canonico`	O doc_id do registro que resolve a citação. Só nas `real`.

§5 Como usar a base

O fluxo tem três passos, e a maior parte da dificuldade está no primeiro.

1 Normalizar o identificador antes de consultar

O índice FTS usa o tokenizador `unicode61`, que quebra em qualquer caractere não alfanumérico. `1.741.784` vira três tokens — `1`, `741`, `784`. A consequência prática:

```
-- funciona: a busca por frase reproduz a sequência de tokens
SELECT d.documento_id, d.id, d.tribunal
  FROM documentos_fts JOIN documentos d ON d.rowid = documentos_fts.rowid
 WHERE documentos_fts MATCH '"1.741.784"';   -- 1 resultado

-- não funciona: sem os separadores, é um token só, que não existe no índice
 WHERE documentos_fts MATCH '1741784';         -- 0 resultados
```

Como o nível 2 entrega números sem pontuação com frequência, o pipeline precisa reconstruir a forma canônica: extrair só os dígitos e reagrupá-los de três em três a partir da direita. `"1 741 784"` como frase também casa, porque produz a mesma sequência de tokens.

Números no padrão CNJ — `0600216-46.2020.6.14.0022` — funcionam do mesmo jeito, com busca por frase.

2 Separar o registro de quem apenas o cita

Esta é a armadilha que mais custa precisão. O FTS devolve qualquer documento que mencione o número, e acórdãos citam uns aos outros o tempo todo. Uma busca por `"1.276.977"` devolve dez documentos do STF — e **nenhum deles é o RE 1.276.977**. Todos apenas o citam.

O sinal que separa os dois casos é a posição. No documento que é o processo, o número está no cabeçalho, nas primeiras dezenas de caracteres. Nos que apenas citam, ele aparece no corpo:

DOCUMENTO	POSIÇÃO	CONTEXTO
doc_0201	20	RECURSO ESPECIAL Nº 1.741.784 - PR …
doc_0001	48	AG.REG. NA RECLAMAÇÃO 76.532 RIO DE JANEIRO …
doc_0149	489	menciona o RE 1.276.977 na ementa — apenas cita
doc_0001	956	também cita o RE 1.276.977, mais adiante

Uma abordagem mais robusta que o limiar de posição é fazer o parsing do cabeçalho: classe processual, número e UF vêm sempre nas primeiras linhas, num formato estável por tribunal. Vale construir esse índice uma vez, offline, e consultar por chave em vez de varrer o FTS a cada citação.

3 Contar os candidatos e decidir a classe

Resolvida a consulta, a cardinalidade do resultado dá a classe quase diretamente. Cada citação `real` do desafio resolve para exatamente um registro da base — as duplicatas remanescentes do acervo não têm nenhuma citação apontando para elas.

CANDIDATOS ENCONTRADOS	CLASSE	SAÍDA
exatamente 1	`real`	`resolucao.id_canonico = a coluna id do registro`
0	`inventada`	`resolucao: null`
2 ou mais candidatos distintos, sem critério de desempate	`incompleta`	`resolucao: null`

Uma citação sem identificadores suficientes para sequer formular a consulta — "jurisprudência pacífica desta Corte", "o dispositivo legal de regência" — é `incompleta` sem passar pelo banco. E uma referência do tipo "acórdão do STF de 2024, relatado pelo Ministro Fulano" é buscável, mas casa com dezenas de candidatos distintos: também `incompleta`, por falta de critério de desempate.

```
-- a consulta por relator+ano que caracteriza a incompleta "buscável"
SELECT COUNT(*) FROM documentos
 WHERE natureza = 'acordao'
   AND tribunal = 'STF' AND ano = 2024
   AND relator LIKE '%Dino%';   -- dezenas de candidatos
```

Leis e súmulas resolvem por registro próprio

Buscar "Súmula 83 do STJ" no texto dos acórdãos devolve dezenas de documentos que a mencionam — nenhum deles é a súmula. Os 18 registros de natureza `sumula` e `dispositivo` existem para isso: são o alvo da resolução, não o texto que cita.

```
-- todos os registros que não são acórdão, com o texto normativo
SELECT documento_id, id, natureza, tipo, substr(texto, 1, 80)
  FROM documentos
 WHERE natureza IN ('sumula', 'dispositivo')
 ORDER BY natureza, id;
```

Como são poucos, o caminho prático é carregá-los em memória e casar por texto normalizado do dispositivo — `art. 373, I, do CPC` e `artigo 373, inciso I, do Código de Processo Civil` apontam para o mesmo `id`.

> **NÃO CONFUNDA AS DUAS COLUNAS DE ID**
>
> `documento_id` é a chave interna do acervo. `id` é o doc_id do Jusbrasil, e é ele que vai em `resolucao.id_canonico`. Entregar `doc_0201` onde se espera `2566535283` derruba a citação para erro, mesmo com a classe certa.

Cobertura congelada em 1.014 registros. O conversor de submissão, `json_to_submission.py`, está na raiz do repositório; a métrica oficial roda no Kaggle.

Atualizado em 28/08/2026 — gen_n2_010 corrigido; doc_0227 e doc_0461 removidos da base (duplicatas exatas); id_canonico passa a ser um único doc_id.

Versão do repositório, adaptada do material oficial da organização em 10/10/2026 — contagens da base (1.014 registros, 996 acórdãos, 94 MB) e do gabarito vigente (192 citações; eram 225); tamanhos médios medidos em data/txt/; dez acórdãos citam o RE 1.276.977 (eram seis); posições contadas a partir de 0; caminhos do repositório; referências a arquivos que não estão no repositório removidas.